


Wykrywanie naczyń dna siatkówki oka

Opis

Przygotowanie aplikacji (okienkowa, Jupyter notebook, ...), która dla zadanego obrazu wejściowego przedstawiającego dno siatkówki oka (przykład poniżej) automatycznie wykrywa naczynia krwionośne. Z formalnego punktu widzenia dla każdego piksela wykorzystany algorytm musi stwierdzić, czy ten piksel stanowi naczynie krwionośne, czy nie (klasyfikacja binarna).



Wymagania obowiązkowe

- Algorytm w podstawowej wersji powinien wykorzystywać techniki przetwarzania obrazu do detekcji naczyń krwionośnych. W ramach takiego procesu przetwarzania można wyróżnić 3 główne elementy:
 - a) *Wstępne przetworzenie obrazu*: wejściowy obraz może być zaszumiony/zbyt ciemny/jasny. Można tutaj wykorzystać takie techniki jak: rozmycie, wyostrenie, normalizacja histogramu kolorów itp.
 - b) *Właściwe przetworzenie obrazu*: w celu wyodrębnienia naczyń krwionośnych: można zastosować różne techniki wykrywania krawędzi (np. filtr Frangi'ego).
 - c) *Końcowe przetwarzanie obrazu*: przetwarzanie uzyskanego obrazu w celu poprawy skuteczności wykrywania naczyń poprzez "naprawę" błędów z poprzednich kroków.

- Wynik obowiązkowo należy wizualizować np. zamalowując wyróżniającym się kolorem piksele zaklasyfikowane jako naczynie krwionośne. W tym celu najlepiej wygenerować binarną maskę odpowiedzi algorytmu, która zostanie potem wykorzystana do analizy statystycznej (porównanie z maską ekspercką z ręcznie zaznaczonymi naczyniami).
- Ważnym elementem oceny jest skuteczność algorytmu. W tym celu należy dokonać podstawowej analizy statystycznej jakości działania algorytmu. Działanie programu należy przetestować na minimum 5 obrazach. Podczas testów należy wyznaczyć macierze pomyłek oraz takie miary jak *trafność* (*accuracy*), *czułość* (*sensitivity*), *swoistość* (*specificity*). Przy wyznaczaniu czułości i swoistości należy założyć, że naczynie to klasa pozytywna, a tło - negatywna. Ponieważ mamy do czynienia z niezrównoważonym rozkładem klas (punktów tła jest znacznie więcej niż naczyń) należy dodatkowo wykorzystać miary dla danych niezrównoważonych (np. średnią arytmetyczną lub geometryczną czułości i swoistości).

Wymagania na 4.0

- Po wstępnym przetworzeniu obrazu należy podzielić go na wycinki (np. 5x5 px) i dla każdej z nich dokonać ekstrakcji cech z obrazu: np. wariancja kolorów, momenty centralne, momenty Hu itp. Wartości te wraz z informacją pochodzącą z maski eksperckiej (decyzja dla środkowego piksela wycinka) stanowią zbiór danych wykorzystany do budowy wybranego klasyfikatora, prostszego niż głęboka sieć neuronowa (np. kNN, drzewo lub las decyzyjny, SVM). Należy skorzystać z gotowej implementacji klasyfikatora (np. w bibliotece scikit-learn).
- Z uwagi na ograniczenia pamięciowe konieczne może być ograniczenie rozmiaru zbioru uczącego poprzez losowy wybór punktów (możliwość zastosowania *undersampling-u* do zrównoważenia rozkładu klas w zbiorze uczącym).
- Zdolności predykcyjne tak opracowanego klasyfikatora należy wstępnie zweryfikować na niezależnym zbiorze testowym *hold-out* (np. pochodzącym z innej części obrazu lub z innego obrazu).
- Gotowy klasyfikator powinien zostać osadzony w aplikacji, a jego działanie powinno zostać zwizualizowane i przetestowane w taki sam sposób, jak działanie technik przetwarzania obrazu z wymagań podstawowych.

Wymagania na 5.0

- Jako model decyzyjny należy wykorzystać głęboką sieć neuronową. W zależności od wybranego rodzaju sieci, może zostać ona nauczona na wycinkach obrazu (podobnie jak w przypadku wymagań na 4.0), jak i na całych obrazach (np. w przypadku sieci

UNet). Należy skorzystać z gotowej implementacji sieci (np. w bibliotece Keras, PyTorch lub TensorFlow).

- Zdolności predykcyjne nauczanej sieci neuronowej powinny być wstępnie zweryfikowane na zbiorze testowym *hold-out*.
- Nauczona sieć powinna zostać osadzona w aplikacji i tam dodatkowo przetestowana zgodnie z wymaganiami obowiązkowymi.

Uwaga

Realizując wymagania na 4.0 lub 5.0 należy także zrealizować wymagania obowiązkowe -- wyniki uzyskane za pomocą prostych metod filtrowania obrazu będą stanowić punkt odniesienia (*baseline*) dla bardziej zaawansowanych modeli decyzyjnych. Realizując wymagania na 5.0 należy również zrealizować wymagania na 4.0, aby porównać działanie obu typów klasyfikatorów.

W projekcie należy skorzystać z jednej z dostępnych baz danych z obrazami (patrz linki poniżej) -- ta sama baza powinna być stosowana we wszystkich krokach projektu.

Raport

Raport powinien zawierać następujące elementy (część z nich dotyczy wymagań na 4.0 i 5.0 - zostało to zaznaczone):

1. Skład grupy
2. Zastosowany język programowania oraz dodatkowe biblioteki
3. Opis zastosowanych metod:
 - a. przetwarzanie obrazów
 - i. poszczególne kroki przetwarzania obrazu (w tym zastosowane filtry),
 - ii. krótkie uzasadnienie zastosowanego rozwiązania,
 - b. uczenie maszynowe (4.0/5.0)
 - i. przygotowanie danych - wyznaczanie wycinków obrazu, ekstrakcja cech z wycinków (jeśli zastosowano)
 - ii. wstępne przetwarzanie zbioru uczącego (jeśli zastosowano)
 - iii. zastosowane metody uczenia maszynowego wraz z informacją o przyjętych parametrach
 - iv. wyniki wstępnej oceny zbudowanego klasyfikatora (testy *hold-out*)
 - v. krótkie uzasadnienie zastosowanego rozwiązania
4. Wizualizacja wyników działania programu dla wybranych obrazów (warto pokazać zarówno sukcesy jak i porażki). Dla porównania należy zamieścić maskę ekspercką (*ground truth*). Wyniki wizualizacji należy zaprezentować dla co najmniej 5 obrazów (w przypadku metod uczenia maszynowego nie mogą to być obrazy, które zostały wykorzystane do nauczania klasyfikatora).

5. Analiza wyników działania programu dla wybranych obrazów (tych samych, które wykorzystano w punkcie 4) z wykorzystaniem odpowiednich miar oceny (omawianych wcześniej). Analizę należy przeprowadzić indywidualnie dla każdego z obrazów. W przypadku realizacji zadań na 4.0/5.0 należy dokonać porównania miar oceny osiągniętych przez metody przetwarzania obrazów oraz uczenia maszynowego.

Linki

- Baza obrazów HRF: <https://www5.cs.fau.de/research/data/fundus-images/> (proszę się nie przejmować komunikatem “website deprecated and outdated”).
- Baza obrazów STARE: <http://cecas.clemson.edu/~ahoover/stare/probing/>
- Baza obrazów CHASE: <https://blogs.kingston.ac.uk/retinal/chasedb1/> (przeglądanie zdjęć nie działa, można jednak pobrać całe archiwum)
- Biblioteka scikit-learn: <https://scikit-learn.org/stable/>
- Biblioteka imbalanced-learn: <https://imbalanced-learn.org/stable/>
- P. Liskowski, K. Krawiec: Segmenting Retinal Blood Vessels With Deep Neural Networks: <https://ieeexplore.ieee.org/document/7440871>
- Implementacja sieci UNet z wykorzystaniem biblioteki PyTorch:
<https://pyimagesearch.com/2023/11/06/image-segmentation-with-u-net-in-pytorch-the-grand-finale-of-the-autoencoder-series/>
<https://pyimagesearch.com/2021/11/08/u-net-training-image-segmentation-models-in-pytorch/>
- MONAI: Medical Open Network for AI: <https://monai.io/>
- Przykładowa implementacja sieci UNet z wykorzystaniem biblioteki Keras:
<https://github.com/zhixuhao/unet>
<https://github.com/karolzak/keras-unet>
https://github.com/qubvel/segmentation_models
- Segmentacja obrazu z wykorzystaniem TensorFlow:
<https://www.tensorflow.org/tutorials/images/segmentation>